

```

1  ### SCRIPT 8 - R ###
2  # Tratamiento y limpieza de datos inicial de los requisitos de licitacion
  empresariales
3  #
4  #####
5  library(ggplot2)
6  library(dplyr)
7  library(openxlsx)
8  library(RODBC)
9  library(quanteda) #paquete recomendado en todos laos
10 library(quanteda.textmodels) #aux
11 library(quanteda.textstats) # aux
12 library(readtext) # sencilla manera de leer data de texto en R
13 library(spacyr) # NLP usando la libreria spaCy, incluyendo etiquetado part-of-speech,
  entity recognition y dependency parsing.
14 library(devtools)
15 library(zoo)
16 library(stringr)
17 #library(SpeedReader) #paquete de github de Stanford, para analisis de texto de alto
  rendimiento
18
19 ### Ruta de trabajo ----
20 setwd("C:/Users/guillermo.alonso/Desktop/Tesis Guillermo/_BD actualizada/Datos
  atom/PLACSP")
21
22 # =====
23 # INTEGRACIÓN DE CRITERIOS DE CUALIFICACIÓN (CODICE)
24 # =====
25
26 # 📌 Cargar librerías necesarias
27 library(dplyr)
28
29 # 📌 Inicializamos data frames vacíos donde iremos acumulando los datos
30 Proy_CCBBD <- data.frame() # Clasificación empresarial exigida (CodeValue)
31 Proy_RTCBD <- data.frame() # Requisitos declarativos (RequirementTypeCode)
32 Proy_TQRBD <- data.frame() # Nodo general con ID, fecha, contrato
33
34 # 📅 Rango de años disponibles
35 anios <- 2012:2025
36
37 # 🔄 Iteramos sobre cada año para cargar y acumular los datos
38 for (anio in anios) {
39   cat("Procesando año:", anio, "\n")
40
41   # 📁 Nombre del archivo .RData correspondiente al año
42   archivo <- paste0("4.30_TendererQualificationRequestet_", anio, ".Rdata")
43
44   # ⚠️ Carga las variables Proy_CC, Proy_RTC, Proy_TQR
45   load(archivo)
46
47   # ➕ Añadimos los datos de este año a los acumuladores
48   Proy_CCBBD <- bind_rows(Proy_CCBBD, Proy_CC)
49   Proy_RTCBD <- bind_rows(Proy_RTCBD, Proy_RTC)
50   Proy_TQRBD <- bind_rows(Proy_TQRBD, Proy_TQR)
51 }
52
53 # =====
54 # 🌟 ¿QUÉ CONTIENE CADA OBJETO?
55 # =====
56
57 # Proy_TQRBD → Cada fila es una solicitud de cualificación
  (`TendererQualificationRequest`)
58 # Incluye:
59 # - Identificador del expediente
60 # - Fecha de actualización (`updated`)
61 # - Código del contrato (`ContractID`)
62 # - Descripción o nota legal
63
64 # Proy_CCBBD → Clasificación empresarial exigida (por ejemplo, K-6, O-2)
65 # Se puede usar para evaluar barreras de entrada (clasificación necesaria
  por volumen o especialidad)
66
67 # Proy_RTCBD → Tipos de requisitos administrativos estandarizados.

```

```

68 # Codificados según el fichero `DeclarationTypeCode-2.0.gc.xml`,
ejemplos:
69 # - 1: Capacidad de obrar
70 # - 2: No prohibición para contratar
71 # - 4: Obligaciones con Hacienda
72
73 # =====
74 # 📁 Guardamos las estructuras unificadas
75 # =====
76
77 save(Proy_CCBD, file = "TendererQualificationRequest.RData") # Clasificación
78 save(Proy_RTCBD, file = "ClassificationCategory.RData") # Requisitos
79 save(Proy_TQRBD, file = "SpecificTendererRequirement.RData") # Nodo raíz
80 completo
81
82 cat("✅ Integración completada. Archivos guardados.\n")
83
84 # =====
85 # CONSTRUCCIÓN DE BD_placsp_quali - SIN FILTRAR LONGITUD
86 # =====
87
88 # 📂 Cargar objetos base
89 load("TendererQualificationRequest.RData") # Proy_TQRBD
90 load("ClassificationCategory.RData") # Proy_CCBD
91 load("SpecificTendererRequirement.RData") # Proy_RTCBD
92
93 # 📖 Cargar librerías
94 library(dplyr)
95 library(stringr)
96
97 # =====
98 # 📌 1. Preparación y renombrado
99 # =====
100
101 Proy_TQRBD <- Proy_TQRBD |>
102   rename(
103     TQR_ID = ID,
104     Identificador = entryID
105   ) |>
106   mutate(
107     updated = as.Date(updated)
108   )
109
110 Proy_CCBD <- Proy_CCBD |>
111   select(TQR_ID, CodeValue) |>
112   filter(!is.na(CodeValue))
113
114 Proy_RTCBD <- Proy_RTCBD |>
115   select(TQR_ID, RequirementTypeCode) |>
116   filter(!is.na(RequirementTypeCode))
117
118 # =====
119 # 🔄 2. Uniones con identificadores y fechas
120 # =====
121
122 # Clasificación empresarial
123 df_cc <- left_join(Proy_TQRBD, Proy_CCBD, by = "TQR_ID") |>
124   select(Identificador, CodeValue, updated) |>
125   distinct()
126
127 # Requisitos tipo declaración
128 df_rtc <- left_join(Proy_TQRBD, Proy_RTCBD, by = "TQR_ID") |>
129   select(Identificador, RequirementTypeCode, updated) |>
130   distinct()
131
132 # =====
133 # 🔄 3. Tratamiento de CodeValue (actualización formato)
134 # =====
135
136 # a) Transformar códigos antiguos (ej. 02d → 02-4)
137 df_transformados <- df_cc %>%
138   filter(str_detect(CodeValue, "[A-Z]\\d[a-i]$")) %>%

```

```

138     mutate(
139       CodeValue = str_replace(CodeValue, "^[A-Z])(\\d)([a-i])$", "\\1\\2-\\3"),
140       CodeValue = chartr("abcdefghi", "123456789", CodeValue)
141     )
142
143 # b) Conservar los códigos ya en formato correcto
144 df_resto <- df_cc %>%
145   filter(!str_detect(CodeValue, "^[A-Z]\\d[a-i]$"))
146
147 # c) Reunir ambos
148 df_cc <- bind_rows(df_transformados, df_resto)
149 rm(df_transformados, df_resto)
150
151 # ⚠ NO se filtra por longitud de CodeValue - se conservan también códigos tipo "K1",
152   "03-", "A*-3", etc.
153
154 # =====
155 # 📊 4. Agrupación final por Identificador
156 # =====
157
158 # A. Clasificación empresarial agrupada
159 df_cc_grouped <- df_cc |>
160   group_by(Identificador) |>
161   summarise(
162     Clasi_empresa = paste(sort(unique(CodeValue)), collapse = ":"),
163     Fecha_actualizacion = max(updated, na.rm = TRUE),
164     .groups = "drop"
165   )
166
167 # B. Requisitos administrativos agrupados
168 df_rtc_grouped <- df_rtc |>
169   group_by(Identificador) |>
170   summarise(
171     Requi_adm = paste(sort(unique(RequirementTypeCode)), collapse = ":"),
172     .groups = "drop"
173   )
174
175 # =====
176 # 🔄 5. Unión final
177 # =====
178
179 BD_placsp_quali <- left_join(df_cc_grouped, df_rtc_grouped, by = "Identificador")
180
181 # ✅ Vista previa
182 print(head(BD_placsp_quali, 10))
183
184 # 📄 Resultado:
185 # - Un identificador por fila
186 # - Clasificación empresarial en formato normalizado y agrupado
187 # - Requisitos administrativos agrupados
188 # - Fecha de actualización más reciente por expediente
189
190 # =====
191 # 📄 6. Extraer sufijos de CodeValue y asignar Clasi_max_req
192 # =====
193
194 # 1. Creamos vector de equivalencias sufijo → capacidad económica en €
195 nivel_economico <- c(
196   "1" = 150000,
197   "2" = 300000,
198   "3" = 450000,
199   "4" = 600000,
200   "5" = 750000,
201   "6" = 1200000,
202   "7" = 2400000,
203   "8" = 5000000,
204   "9" = 5000001
205 )
206
207 # 2. Extraemos todos los sufijos como string desde Clasi_empresa
208 # Esto genera una lista de strings con todos los "-[n]" encontrados
209 sufijos_raw <- str_extract_all(BD_placsp_quali$Clasi_empresa, "-[1-9]")

```

```

210
211 # 3. Limpiamos los sufijos para dejar solo los dígitos
212 # Convertimos la lista a vector numérico del máximo por fila
213 max_sufijo <- sapply(sufijos_raw, function(x) {
214   if (length(x) == 0) return(NA_real_)
215   nums <- as.numeric(gsub("-", "", x))
216   max(nums, na.rm = TRUE)
217 })
218
219 # 4. Añadimos la nueva variable Clasi_max_req al data frame
220 BD_placsp_quali <- BD_placsp_quali |>
221   mutate(
222     Clasi_max_req = nivel_economico[as.character(max_sufijo)]
223   )
224
225 # Exportar BD_placsp_quali
226 save(BD_placsp_quali, file = "BD_placsp_quali.RData")
227 write.xlsx(BD_placsp_quali, "BD_placsp_quali.xlsx", colNames = TRUE, rowNames = FALSE)
228
229
230
231

```